

Regression – Youtube Statistics

Team:

1. Alya Rahma Rahadian
-

Simple Exploratory Data Analysis

Pertama dilakukan EDA menggunakan statistika deskriptif dan visualiasi terhadap variabel-variabel dari data youtube statistics.

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 36791 entries, 0 to 36790
Data columns (total 18 columns):
 #   Column                Non-Null Count  Dtype  
---  -
 0   trending_date          36791 non-null  object 
 1   title                  36791 non-null  object 
 2   channel_title          36791 non-null  object 
 3   category_id            36791 non-null  int64  
 4   publish_time           36791 non-null  object 
 5   tags                   36791 non-null  object 
 6   views                  36791 non-null  int64  
 7   likes                  36791 non-null  int64  
 8   dislikes               36791 non-null  int64  
 9   comment_count          36791 non-null  int64  
10  comments_disabled      36791 non-null  bool    
11  ratings_disabled       36791 non-null  bool    
12  video_error_or_removed 36791 non-null  bool    
13  description            36746 non-null  object 
14  No_tags                36791 non-null  int64  
15  desc_len               36791 non-null  int64  
16  len_title              36791 non-null  int64  
17  publish_date           36791 non-null  datetime64[ns]
dtypes: bool(3), datetime64[ns](1), int64(8), object(6)
memory usage: 4.3+ MB
```

df.info() dari Data Youtube Statistics

Dataset terdiri dari 36.791 baris dan 18 variabel, yang mencakup: Variabel numerik (views, likes, dislikes, comment_count, dll.), variabel kategorikal (title, channel_title, tags), variabel boolean (comments_disabled, ratings_disabled, video_error_or_removed), variabel waktu (publish_date, trending_date). Tidak terdapat missing value kecuali 45 baris pada kolom description.

	category_id	views	likes	dislikes	comment_count	No_tags	desc_len	len_title
count	36791.000000	3.679100e+04	3.679100e+04	3.679100e+04	36791.000000	36791.000000	36791.000000	36791.000000
mean	21.552173	1.071490e+06	2.745069e+04	1.685363e+03	2714.022043	18.938463	923.079123	70.609361
std	6.586716	3.207149e+06	9.783129e+04	1.619732e+04	14978.114328	9.843531	815.038867	22.409174
min	1.000000	4.024000e+03	0.000000e+00	0.000000e+00	0.000000	1.000000	3.000000	5.000000
25%	23.000000	1.256040e+05	8.790000e+02	1.090000e+02	83.000000	12.000000	368.000000	53.000000
50%	24.000000	3.078360e+05	3.126000e+03	3.310000e+02	336.000000	19.000000	677.000000	74.000000
75%	24.000000	8.066315e+05	1.409500e+04	1.032000e+03	1314.500000	25.000000	1237.000000	91.000000
max	43.000000	1.254322e+08	2.912710e+06	1.545017e+06	827755.000000	72.000000	5136.000000	100.000000

Statistika Deskriptif Variabel Numerik dengan df.describe()

Distribusi views, likes, dislikes, dan comment_count sangat right-skewed Nilai maksimum jauh lebih besar dari median yang bisa jd indikasi outlier ekstrem Rata-rata views (+1 juta) jauh lebih tinggi dari median (+300 ribu) Hal ini wajar pada data YouTube karena sebagian kecil video viral mendominasi jumlah views.

	trending_date	title	channel_title	publish_time	tags	comment_s_disabled	ratings_disabled	video_err_or_or_removed	description
count	36791	36791	36791	36791	36791	36791	36791	36791	36746
unique	205	16431	1390	12375	12463	2	2	2	13979
top	2017-12-23	Mission: Impossible - Fallout (2018) - Official...	VikatanTV	04:30:00	[none]	False	False	False	Subscribers Link: http://bit.ly/2qb69dZ\n\nCon...
freq	199	19	284	333	1120	35611	36034	36780	166

Statistika Deskriptif Variabel Kategorikal

Terdapat 205 tanggal unik video masuk trending. Tanggal yang paling sering muncul adalah 2017-12-23 dengan 199 video, yang mengindikasikan bahwa pada tanggal tersebut terjadi lonjakan jumlah video yang masuk trending. Dari 36.791 video, terdapat 16.431 judul unik, yang berarti sebagian besar judul hanya muncul satu kali. Judul yang paling sering muncul adalah "Mission: Impossible - Fallout (2018) - Official ..." sebanyak 19 kali, kemungkinan karena video tersebut diunggah ulang atau muncul berkali-kali dalam daftar trending di hari berbeda. Terdapat 1.390 channel unik, dengan channel VikatanTV sebagai yang paling sering muncul (284 kali). Ini


menunjukkan bahwa channel tertentu memiliki probabilitas lebih tinggi untuk masuk trending, kemungkinan karena basis subscriber besar atau konsistensi konten.

Ada 12.375 waktu unggah unik, namun waktu 04:30:00 paling sering digunakan (333 kali). Ini mengindikasikan adanya pola jam unggah tertentu yang populer di kalangan kreator, meskipun belum tentu optimal secara performa views. Sebanyak 12.463 kombinasi tag unik, dengan tag "[none]" paling sering muncul (1.120 kali). Artinya cukup banyak video trending yang tidak menggunakan tag sama sekali, sehingga tag bukan satu-satunya faktor penentu video masuk trending.

Mayoritas video tidak menonaktifkan komentar (False sebanyak 35.611 video). Hal ini menunjukkan bahwa interaksi komentar umumnya tetap dibuka pada video trending, yang bisa berkontribusi pada engagement. Sebagian besar video tidak menonaktifkan rating (False sebanyak 36.034 video). Ini mengindikasikan bahwa like/dislike merupakan fitur penting dalam video trending dan jarang dimatikan. Hampir seluruh video tidak mengalami error atau penghapusan (False sebanyak 36.780 video).


Terdapat 13.979 deskripsi unik, dengan satu deskripsi paling sering muncul sebanyak 166 kali. Ini kemungkinan berasal dari template deskripsi channel tertentu (misalnya link subscribe), sehingga panjang deskripsi lebih relevan dibanding isi teks mentah.

Analisis Univariat dengan Visualisasi




Histogram Variabel Numerik

Berdasarkan visualisasi univariat menggunakan histogram, dapat dilihat bahwa variabel views, likes, dislikes, dan comment_count memiliki pola sebaran yang tidak simetris (right-skewed) bentuk yang tipis ekstrim seperti ini juga bisa menjadi indikasi bahwa sebaran dari outlier begitu besar sehingga harus diatasi apabila memang demikian.




Boxplot Variabel Numerik

Sesuai dengan histogram, boxplot multivariat menunjukkan bahwa sebagian besar variabel numerik memiliki banyak outlier, terutama pada views, likes, dislikes, dan comment_count. Hal ini wajar mengingat karakteristik data media sosial yang bersifat viral, di mana hanya sebagian kecil video yang memiliki nilai ekstrem sangat tinggi.



Plot Tanggal Trending


Grafik jumlah video yang masuk trending berdasarkan tanggal menunjukkan bahwa jumlah video trending relatif stabil dari waktu ke waktu, dengan fluktuasi harian yang tidak terlalu ekstrem. Namun terdapat beberapa penurunan tajam pada periode tertentu, yang kemungkinan disebabkan oleh faktor eksternal yang tidak dapat disimpulkan saat ini.



Countplot untuk Variabel Boolean


Sebagian besar dari video viral memiliki fitur komentar dan rating yang dinyalakan dan hanya 11 dari keseluruhan data yang memiliki kendala video error ataupun removed (kurang dari 1%).

Analisis Multivariat dengan Visualisasi



Pairplot Variabel Numerik Youtube Statistics

Berdasarkan visualisasi multivariate menggunakan pairplot, dapat dilihat bahwa variabel views, likes, dislikes, dan comment_count memiliki pola sebaran yang tidak simetris (right-skewed) serta menunjukkan hubungan yang cenderung linear satu sama lain, kecuali views dengan likes yang meskipun terlihat memiliki hubungan cenderung positif tetapi memiliki pola yang agak melengkung. Hal ini mengindikasikan bahwa video dengan jumlah views tinggi umumnya juga memiliki likes, dislikes, dan komentar yang tinggi. Pola ini memperkuat dugaan bahwa engagement pengguna sangat berkaitan erat dengan jumlah views.



Heatmap Korelasi antar Variabel Numerik

Berdasarkan matriks korelasi, variabel yang memiliki hubungan paling kuat dengan views adalah likes (0,85), comment_count (0,67), dan dislikes (0,54). Hal ini menunjukkan bahwa metrik interaksi pengguna memiliki peran besar dalam menjelaskan jumlah penayangan video. Video dengan jumlah likes dan komentar yang tinggi cenderung memiliki views yang tinggi pula. Namun, terlihat juga bahwa likes, dislikes, dan comment_count saling berkorelasi cukup tinggi satu sama lain (misalnya likes–comment_count = 0,78 dan dislikes–comment_count = 0,71), yang mengindikasikan adanya potensi multikolinearitas pada model regresi linier biasa.

Variabel lain seperti No_tags, desc_len, dan len_title menunjukkan korelasi yang relatif lemah terhadap views, sehingga kontribusinya bersifat tambahan dan tidak dominan. Sementara itu, variabel boolean seperti comments_disabled, ratings_disabled, dan video_error_or_removed hampir tidak berkorelasi dengan views, yang berarti pengaruhnya terhadap jumlah views tidak linear atau tidak kuat secara langsung. Selain itu, category_id memiliki korelasi negatif lemah terhadap views (-0,18), mengindikasikan bahwa perbedaan kategori memang berpengaruh, tetapi bukan faktor utama. Secara keseluruhan, temuan ini mendukung penggunaan Ridge Regression, karena model ini lebih robust terhadap multikolinearitas dibandingkan regresi linear biasa.

Data Preprocessing

Hal-hal yang dilakukan pada proses preprocessing:

- Checking for Null-Value

Tidak terdapat null value kecuali pada beberapa row description, akan tetapi diputuskan untuk tidak dihapus dikarenakan kolom ini sudah direpresentasikan oleh desc_len yang tidak memiliki null value.

- Checking for Duplicate Value


```
df.duplicated().sum()
```

4229

Terdapat 4229 data duplikat. Pada kasus ini dikarenakan data yang dimiliki sudah cukup banyak dan mengingat seharusnya cukup sulit untuk terdapat sebanyak itu row data dengan nilai sama dengan banyaknya variabel bahkan yang mendetail seperti waktu, judul, hingga deskripsi, maka diputuskan lah untuk menghapus 4229 row data.

- Outliers Handling

Outlier diidentifikasi menggunakan Z-score (>3) dan IQR method. Alih-alih menghapus data, dilakukan winsorization (clipping) pada variabel numerik untuk menjaga ukuran dataset, mengurangi pengaruh nilai ekstrem, dengan tetap mempertahankan pola distribusi.



Sesudah data cleaning dapat dilihat bahwa tidak terdapat lagi extreme outliers dan siap digunakan untuk analisis, meskipun masih terdapat pola skewness yang mirip seperti semula. Akan tetapi muncul puncak-puncak kecil, terutama di ujung data, hal ini normal

dikarenakan Outliers dihandle dengan cara dimasukkan sebagai nilai maksimal/minimal dari IQR, yang membuat adanya lonjakan jumlah data pada titik-titik tersebut.

Feature Engineering

Feature Engineering yang dilakukan:

- Melakukan Label Enconding untuk variabel boolean
- Melakukan ekstraksi variabel jam publish (hour) dari publish time untuk mengetahui kisaran jam yang sering dijadikan momentum untuk upload
- Melakukan ekstraksi variabel weekend untuk mengetahui apakah video diupload di akhir pekan atau hari kerja dari publish date.

Feature Selection:

- Y/Target: views (bilangan bulat, rasio)
- X/Prediktor:

0	category_id	32562	non-null	int64
1	likes	32562	non-null	float64
2	dislikes	32562	non-null	float64
3	comment_count	32562	non-null	float64
4	No_tags	32562	non-null	float64
5	desc_len	32562	non-null	float64
6	len_title	32562	non-null	int64
7	disabled_comms	32562	non-null	int64
8	disabled_ratings	32562	non-null	int64
9	error	32562	non-null	int64
10	publish_hour	32562	non-null	int64
11	is_weekend	32562	non-null	int64

Modeling

Model linear regression digunakan sebagai baseline dengan seluruh fitur numerik. Hasil evaluasi menunjukkan RMSE sebesar ± 280.436 dan R^2 sebesar 0,7349, yang berarti sekitar 73,5% variasi views dapat dijelaskan oleh fitur-fitur dalam model. Nilai ini sudah cukup baik untuk model linear sederhana, namun masih berpotensi ditingkatkan mengingat adanya indikasi multikolinearitas pada data.

Model	RMSE	R^2
Linear Regression (lengkap)	280,436.23	0.7349
Linear Regression (tanpa comment_count)	281,745.40	0.7330

Eksperimen dilakukan dengan menghapus variabel comment_count karena memiliki korelasi sangat tinggi dengan likes ($\approx 0,89$). Hasilnya, performa model justru menurun, dengan RMSE meningkat menjadi ± 281.745 dan R^2 turun menjadi 0,7330. Hal ini menunjukkan bahwa meskipun terdapat korelasi tinggi, comment_count tetap mengandung informasi penting dalam menjelaskan variasi views. Dengan demikian, variabel ini dipertahankan pada pemodelan selanjutnya.

Model	RMSE	R ²
Linear Regression	280,436.23	0.7349
Ridge Regression	280,422.43	0.7349
Lasso Regression	280,433.94	0.7349
ElasticNet	281,221.15	0.7334

Tiga model regularisasi diuji untuk mengatasi potensi multikolinearitas, yaitu Ridge, Lasso, dan ElasticNet. Dari hasil evaluasi, Ridge Regression memberikan performa terbaik, dengan RMSE terendah (± 280.422) dan R² tertinggi (0,7349). Lasso dan ElasticNet menunjukkan performa yang sedikit lebih rendah, yang mengindikasikan bahwa penalti L1 (atau kombinasi L1–L2) kurang optimal untuk karakteristik data ini.

```
Out[57]: GridSearchCV(cv=5,
                    estimator=Pipeline(steps=[('scaler', StandardScaler()),
                                              ('ridge', Ridge())]),
                    n_jobs=-1,
                    param_grid={'ridge__alpha': array([1.00000000e-04, 2.63665090e-04, 6.95192796e-04, 1.83298071e-03,
4.83293024e-03, 1.27427499e-02, 3.35981829e-02, 8.85866790e-02,
2.33572147e-01, 6.15848211e-01, 1.62377674e+00, 4.28133240e+00,
1.12883789e+01, 2.97635144e+01, 7.84759970e+01, 2.06913808e+02,
5.45559478e+02, 1.43844989e+03, 3.79269019e+03, 1.00000000e+04])},
                    scoring='r2')
```

```
In [58]: print(grid.best_params_)
print(grid.best_score_)

{'ridge__alpha': 4.281332398719396}
0.7348846012795406
```

Setelah dilakukan GridSearchCV untuk parameter alpha dengan skema 5-fold cross-validation dan coring menggunakan R² didapatkan Hasil:

Alpha terbaik ≈ 4.28

```
In [59]: best_model = grid.best_estimator_

r2_test = best_model.score(X_test, y_test)
y_pred = best_model.predict(X_test)
rmse = mean_squared_error(y_test, y_pred, squared=False)
print(f"R^2 : {r2_test}")
print(f"RMSE : {rmse}")

R^2 : 0.7349003104382962
RMSE : 280433.551596802
```

Dengan paramter terbaik didapatkan model stabil dengan R² sebesar 73.49% dan RMSE 280433.55.

Output Hyperparameter Tuning di Python

Hyperparameter tuning dilakukan menggunakan GridSearchCV dengan 5-fold cross-validation dan metrik R². Parameter yang dituning adalah alpha, yang mengontrol kekuatan regularisasi. Hasil tuning menunjukkan alpha terbaik adalah sebesar 4,28. Model hasil tuning memiliki R² sebesar 0,7349 dan RMSE 280.433,55 yang relatif stabil dan konsisten dengan model ridge tanpa tuning. Penurunan kecil pada performa uji wajar terjadi karena model menjadi lebih general (tidak overfitting ke data training).

Summary

Kesimpulan

Diantara 5 model regresi yang diuji; Model Linear, Model Linear tanpa variabel prediktor berkorelasi tinggi, Model Ridge, Model Lasso, dan Model Elastic Net, didapat bahwa model Ridge memiliki nilai evaluasi metrik paling baik; dengan R^2 tertinggi yakni 0,7249 atau 73.49% dan juga RMSE terendah yakni 280.422,43.

Setelah dilakukan hyperparameter tuning dengan 5 fold cross validation didapat bahwa nilai alpha terbaik sebesar 4,28 dengan R^2 0,7349 atau 73.49% dan juga RMSE terendah yakni 280.433,55.

Saran

Mengingat ada pola yang sedikit melengkung pada visualisasi antar variabel X dan Y, maka dapat dilakukan perbandingan eksperimen dengan metode lain yang tidak mengharuskan hubungan linear antara prediktor dan target, seperti random forest di lain waktu.